

分 类 号_____

密 级_____

U D C_____

编 号 10486

武汉大学

硕 士 学 位 论 文

基于 Inception 和混合注意力的运动想象
脑电图分类研究

研 究 生 姓 名：刘梓轩

学 号：2021202110015

指导教师姓名、职称：李石君 教授

专 业 名 称：计算机科学与技术

研 究 方 向：机器学习与应用

二〇二四年四月

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者（签名）：

年 月 日

摘 要

论文的摘要是对论文研究内容和成果的高度概括。摘要应对论文所研究的问题及其研究目的进行描述，对研究方法和过程进行简单介绍，对研究成果和所得结论进行概括。摘要应具有独立性和自明性，其内容应包含与论文全文同等量的主要信息。使读者即使不阅读全文，通过摘要就能了解论文的总体内容和主要成果。

论文摘要的书写应力求精确、简明。切忌写成对论文书写内容进行提要的形式，尤其要避免“第 1 章……；第 2 章……；……”这种或类似的陈述方式。

关键词是为了文献标引工作、用以表示全文主要内容信息的单词或术语。关键词不超过 5 个，每个关键词中间用分号分隔。

关键词：脑机接口；运动想象；脑电图；注意力；深度学习

ABSTRACT

An abstract of a dissertation is a summary and extraction of research work and contributions. Included in an abstract should be description of research topic and research objective, brief introduction to methodology and research process, and summary of conclusion and contributions of the research. An abstract should be characterized by independence and clarity and carry identical information with the dissertation. It should be such that the general idea and major contributions of the dissertation are conveyed without reading the dissertation.

An abstract should be concise and to the point. It is a misunderstanding to make an abstract an outline of the dissertation and words “the first chapter”, “the second chapter” and the like should be avoided in the abstract.

Keywords are terms used in a dissertation for indexing, reflecting core information of the dissertation. An abstract may contain a maximum of 5 keywords, with semi-colons used in between to separate one another.

Key words: BCI; Motor Imagery; EEG; attention; Deep Learning

目 录

摘 要	I
ABSTRACT	III
1 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 基于先验知识的运动想象脑电图特征研究现状	2
1.2.2 基于深度学习的运动想象脑电图分类研究现状	3
1.3 研究内容	3
1.4 论文组织结构	3
2 运动想象脑电图分类和深度神经网络基础	5
2.1 脑电生理基础	5
2.2 深度神经网络基础	5
2.3 基于深度学习的运动想象脑电图分类基础	5
2.4 本章小结	5
3 基于 Inception 和混合注意力的运动想象脑电图分类网络构建	7
3.1 基于 EEGNet 和注意力机制的紧凑型基础网络 VSNet	7
3.1.1 注意力机制	8
3.1.2 ShallowConvNet 结合注意力机制的紧凑型 MI-EEG 分类网络	10
3.2 基于密集连接改进的 Inception 模块	13
3.2.1 特征提取基础结构	15
3.2.2 密集连接	18
3.2.3 基于密集连接改进的 Inception 模块	19
3.3 基于软阈值化改进的 Transformer 模块	22
3.4 基于 Inception 和混合注意力的运动想象脑电图分类网络 HIT-Net	22
3.5 本章小结	22
4 实验结果分析与模型评估	23
5 总结与展望	25
参考文献	27

致谢	31
----------	----

1 绪论

1.1 研究背景及意义

大脑是一个结构和功能都很复杂的器官，是人体内外环境信息获得、存储、处理、加工及整合的中枢^[1]，其神经活动蕴含着丰富的信息，直接反映了人类的思维、情绪和行为意图。对大脑的研究，不仅可以防止大脑的衰退以及脑疾病的产生，而且可以通过模拟大脑促进人工智能的发展^[2]。

现今世界，各国政府及科研机构都高度重视脑科学研究的发展，美国于 2013 年启动“创新性神经技术大脑研究”计划，旨在开发和应用新的工具和技术，彻底改变人类对大脑的理解^[3]。日本于 2014 年启动“脑/思维”计划，研究集中在三个领域：猕猴大脑的结构和功能图谱，用于脑图绘制的创新神经技术，以及人类脑图谱^[4]。欧盟于 2013 年启动“人类脑计划”，最初目标为通过超级计算机对人脑进行模拟，该项目已于 2023 年 9 月结束，其在神经科学领域取得了多项重大进展^[5]。中国于 2021 年将“脑科学与类脑研究”列为科技创新 2030 重大项目^[6]，正式启动了“中国脑计划”，其内容包括认知神经机制的基础研究，脑疾病诊断和干预的转化研究以及脑启发智能（类脑）技术^[7]。

脑机接口（Brain Computer Interface, BCI）是脑科学与信息科学交叉产生的新兴学科领域，研究如何在大脑与外部设备之间建立直接的通信和控制通道，实现脑与设备之间的双向信息传输。脑机接口系统的目标是将人类的思维、意愿或行动指令实时转化为可识别的控制信号，从而使人类可以直接由大脑而非神经肌肉通路来控制计算机或设备，双向脑机接口系统不仅可以实现大脑控制，也为通过神经接口调节中枢神经系统提供了一种可能的方案^[8]。脑机接口的基础在于采集大脑活动产生的生物信号，例如脑电图（Electroencephalography, EEG）、功能性磁共振成像（Functional Magnetic Resonance Imaging, fMRI）、近红外光谱（Near-Infrared Spectroscopy, NIRS）等，这些生物信号从不同角度反映了大脑的认知过程、情绪状态和意图表达，其中，脑电图以其实时性、灵活性、便携性、低成本、非侵入性、高时间分辨率等优点，在脑机接口研究领域受到了广泛的应用。

运动想象（Motor Imagery, MI）是脑机接口研究的主要方向之一，其表征的是一种运动意图，即个体在不实际执行物理动作的情况下，在大脑中想象执行特定动作的一种心理过程。运动想象的研究源于对大脑功能区域的认知神经科学探索，研究发现，当人们想象执行某个动作时，即使身体并未实际做出该动作，大脑中的特定脑区仍会有所激活。这种现象为基于运动想象的脑机接口系统提供了理论基础，通过识别和解码运动想象相关的脑电信号，可以基于使用者的自主意识实现对辅助设备的非侵入式控制，其在运动功能代偿、运动功能修复^[9]、智能人机协作、认知神经科学研究等领域具有广阔的

应用前景。

近年来,随着认知神经科学的持续发展以及各国政府对脑科学的日益重视,运动想象研究领域逐渐吸引了广泛的关注。在基于脑电图信号进行运动想象分类的研究中,鉴于脑电信号固有的复杂性与异质性,传统机器学习方法通常需要依据神经科学领域的先验知识进行人工特征设计,随着深度学习的迅速发展,研究者们开始将深度神经网络应用于运动想象分类任务中,期望能够自动化提取和学习脑电图信号中蕴含的潜在特征,然而,受限于数据集规模、脑电数据质量、实时响应性能等因素,深度学习在该领域的应用效果尚未达到理想的水平。

综上所述,尽管运动想象研究已积累了一系列有价值的科研成果,但是依然存在一定的进步空间。目前基于脑电图的运动想象分类任务仍然存在以下问题:

1. 脑电信号,运动想象的数据集
2. 端到端,实时响应性能
3. 分类准确率
4. 可解释性

针对这些问题,论文进行了

1.2 国内外研究现状

不同于常规的时间序列数据,运动想象脑电图数据具有独特的生理学特征,因此,对基于神经科学先验知识进行的特征提取研究进行回顾,有利于运动想象领域的深度神经网络的设计。因此,本节将从脑电图特征提取和深度神经网络应用两方面来系统性地介绍运动想象领域的国内外研究现状。

1.2.1 基于先验知识的运动想象脑电图特征研究现状

传统机器学习中,对运动想象脑电图信号(MI-EEG)的处理通常分为预处理、特征提取和分类三个主要步骤^[10],其中,分类算法与其它领域内广泛采用的传统机器学习技术类似,因此,论文主要介绍与 MI-EEG 信号生理特性相关的预处理技术和特征提取方法的相关研究。

MI-EEG 信号的信息密度在不同通道和频段间呈现出显著差异,并且数据的采集极易受到设备、环境、个体生理状态等因素的干扰,从而产生大量噪声,因此,对 MI-EEG 信号进行预处理是有必要的。预处理步骤包括一系列操作,例如通道选择(为 MI 任务选择最有价值的 EEG 通道)、信号滤波(为 MI 工作选择最有意义的频率范围)、信号归一化(围绕时间轴对每个 EEG 通道进行归一化)、伪影去除(从 MI-EEG 信号中去除噪声)^[10]、基线校正(消除 EEG 数据漂移带来的影响)等。其中,伪影去除的经典方法是独立成分分析(Independent Component Analysis, ICA)和离散小波变换^[11]。

MI-EEG 信号的特征主要分为三类:时域特征、频域特征和空间域特征^[10],此外,

通过对原始数据的进一步加工和转换，可以构建一系列复合特征，如时频特征、时空特征、时频空特征等。

时域特征反映 EEG 信号随时间变化的特性，其包括均值、方差、标准差、峰度、偏度等统计量，此外，Bo Hjorth 提出了一种快速计算时变信号的三个重要特征的方法，即活动性、移动性和复杂性，统称为 Hjorth 参数^[12]，Luke 等人使用卡尔曼滤波来处理 EEG 信号的不确定性^[13]，考虑到 EEG 信号具有分形性质，Hsu 提出了一种将分形维数和离散小波变换相结合的方法^[14]。空域特征反映 EEG 信号在不同脑电极上的分布情况，共空间模式（Common Spatial Pattern, CSP）是空域特征提取的经典方法，其核心思想是寻找一组最优的空间滤波器，通过这组滤波器对原始多通道 EEG 数据进行空间投影，从而最大化两类信号在投影后空间的方差差^[15]。研究者对 CSP 算法进行了进一步优化，提出了滤波器组共空间模式（FBCSP）^[16]、共稀疏空间谱模式（CSSSP）^[17]、共空间谱模式（CSSP）^[18]、小波共空间模式（WCSP）^[19] 等方法，在多分类、异步脑机接口等领域取得了更好的效果。频域特征反映 EEG 信号在不同频带的功率，通常包括功率谱、功率谱密度、高阶谱、微分熵、傅里叶变换等方法。Wang 等人提出了一种基于快速傅里叶变换的功率谱特征提取方法^[20]，Kroupi 等人使用基于 Welch 方法的功率谱密度（PSD）估计来进行脑电情感分析^[21]，Herman 等人比较分析了不同的频率特征在运动想象分类中的效果，并证实了功率谱密度具有最好的鲁棒性^[22]。时频特征由于结合了时域特征和频域特征，在基于非平稳 EEG 信号的脑机接口研究中获得了广泛的使用^[23]，其主要包括匹配滤波、自回归模型、短时傅里叶变换、小波变换等方法，时频特征在提升了分类精度的同时，也提高了计算的复杂度。

尽管关于 EEG 信号特征提取的研究已积累了大量成果，然而传统预处理及特征提取方法仍存在着计算复杂度较高以及信息丢失的可能性，同时，EEG 信号的特征提取高度依赖神经科学领域的先验知识，从而限制了特征提取的自动化程度^[10]。在这种背景下，深度学习被引入运动想象分类领域，以克服传统方法存在的问题。

1.2.2 基于深度学习的运动想象脑电图分类研究现状

1.3 研究内容

1.4 论文组织结构

2 运动想象脑电图分类和深度神经网络基础

2.1 脑电生理基础

2.2 深度神经网络基础

2.3 基于深度学习的运动想象脑电图分类基础

2.4 本章小结

3 基于 Inception 和混合注意力的运动想象脑电图分类网络构建

论文前两个章节主要对运动想象脑电图分类领域的基础知识以及相关研究做了一定的介绍，并且对该领域仍然存在的问题进行了分析。本章对这些问题进行进一步的探讨，针对这些问题构建了一种端到端的新模型：首先，以 ShallowConvNet 为基础，引入深度可分离卷积和轻量级注意力模块，减少网络参数，提高对重要通道数据的关注，同时促进时空特征的深度融合；其次，在以上模型的基础上，引入 Inception 模块替代时间卷积层，并行提取多尺度的时间特征，对该结构进行进一步改造，将密集连接引入 Inception 模块的分支中，更好地关注 EEG 信号的局部细节和浅层特征；最后，引入 Transformer 模块以更好地利用 EEG 信号的全局信息，并且针对 EEG 信号信噪比低的特点，引入软阈值模块对 Transformer 进行改进，从而减少噪声的干扰。经过以上一系列改进，最终构建了一种基于 Inception 和混合注意力的运动想象脑电图分类网络 HIT-Net，在运动想象脑电图分类任务上能够取得更好的效果。

3.1 基于 EEGNet 和注意力机制的紧凑型基础网络 VSNet

原始的 EEG 信号通常为二维数据，包括通道（电极）和时间两个维度，具体而言，在 EEG 信号矩阵中，行代表分布在头皮不同位置的采样通道，列为时间序列数据，每个采样点对应一个时间戳下的生物电信号（通常为电压值），因此，一列数据就是一个特定时间点下所有通道同步采集到的电压读数。原始的 EEG 信号经过预处理之后，可以转换为时频图、头皮点位拓扑图等输入模式，尽管经过转换的输入相较于原始输入能够更全面地体现 EEG 信号的时频空信息，但这一过程往往需要具有神经科学背景的人工参与，在增加了人工成本同时，限制了模型自适应学习 EEG 信号中蕴含的复杂时空特征的能力，此外，复杂的预处理环节也增加了计算开销和应用成本，难以满足 BCI 系统即时响应的需求。因此，端到端网络在 MI-EEG 分类领域受到越来越多的重视，这类网络不经过或者仅仅经过很少的预处理步骤，而由深度学习算法自适应地提取关键特征并作出预测。

ShallowConvNet^[24] 是一个专为端到端解码脑电图（EEG）信号而设计的深度学习架构，其构思源自 EEG 信号解码研究领域广泛使用的经典特征提取方法——滤波器组共空间模式（Filter Bank Common Spatial Pattern, FBCSP）^[16]。ShallowConvNet 具有 FBCSP 算法对频带功率特征高效提取的特性，在实验中证明了能够学习频带功率变化的时间结构特性^[24]，研究发现，该特性有助于提高分类性能^[25]。实验证明，ShallowConvNet 在 MI-EEG 分类领域具有优良的性能^[26]，同时具有较少的参数量，因此论文以 ShallowConvNet




图 3.1 ShallowConvNet 结构

为基础搭建紧凑型 MI-EEG 分类网络。

ShallowConvNet 的结构如图 3.1 所示。ShallowConvNet 采用四步流程对原始二维输入数据进行处理。具体而言，ShallowConvNet 首先通过时间卷积层捕获信号的时间域特征，再通过空间卷积层捕获这些时间特征在不同通道间的空间关联性，随后通过平均池化层进行下采样，最后通过全连接层将多维特征映射至分类输出空间。ShallowConvNet 采取的时间卷积和空间卷积相分离的策略有效地减少了模型参数量，同时，空间卷积核能够学习其对应的时间卷积核提取的特征，这种设计隐含了对 FBCSP 算法核心思想的借鉴与实现。

3.1.1 注意力机制

注意力机制的提出受到人类认知科学的启发，其核心理念在于模拟人类大脑在处理信息过程中的选择性关注机制，即并非均匀地分配注意力处理对待所有输入，而是将注意力主动、动态且有选择性地聚焦于最重要或最相关的信息上。自二十世纪被提出以来^[27]，注意力机制在计算机视觉、自然语言处理等领域得到了广泛的应用，并表现出了优秀的效果。根据神经科学先验知识，EEG 信号中不同的通道和采样点具有不同的重要性，这为在 MI-EEG 分类领域应用注意力机制提供了理论依据，此外，将二维 EEG 信号视为一种由通道和时间两个维度构成的特殊图像，使得在 MI-EEG 分类领域能够迁移应用计算机视觉领域中的注意力机制。

计算机视觉领域中经常使用的注意力机制有：

1. 通道注意力机制

不同于 EEG 信号中代表电极的通道，计算机视觉领域的通道代表图像的不同特征映射。通道注意力机制用于调整不同特征通道的重要性，通常会对每一个特征通道计算一些全局统计量，如均值、方差等，再将这些统计量经过非线性变换层进行编码，最后将编码向量进行转换并用于各个特征通道的加权。通道注意力机制的经典模型是压缩和激励网络 (Squeeze-and-Excitation Networks, SENet)^[28]，其主要思想即是压缩 (Squeeze) 和激励 (Excitation)，SENet 首先通过压缩操作获取全局上下文信息，然后通过激励操作对每个通道独立生成权重系数。具体而言，在压缩操作中，SENet 在空间维度执行全




图 3.2 CBAM 结构

局池化操作，将每个通道的特征图汇总成一个标量值；然后，在激励操作中，SENet 通过一个全连接网络生成每个通道的权重系数，这些权重系数用于重新加权每个通道的特征图，以增强有用的特征并抑制无用的特征。

在后文中，为避免与计算机视觉领域中的概念相混淆，在 MI-EEG 分类任务中，用深度来代表 EEG 信号的不同特征映射，而通道仍然代表电极。

2. 空间注意力机制

在计算机视觉领域中，空间注意力机制用于调整图片、视频等输入数据在空间维度中不同区域的重要性，通常会在深度维度上通过全局池化、卷积、特征融合等操作生成一个与特征图尺寸相同的注意力图，其值反映了空间维度中不同区域的注意力强度，最后，将注意力图进行转换，并用于原始特征图的加权。空间注意力机制的经典模型是空间变换网络（Spatial Transformer Network, STN）^[29]，其具有对输入数据进行空间变换的能力，能够自动捕获重要区域的特征。

3. 混合注意力机制

混合注意力机制是一种集成多种注意力机制（如空间注意力、通道注意力及自注意力等）的方法，旨在更全面地捕获和整合输入数据在不同维度的有效信息。混合注意力机制通常会使用不同的注意力机制分别计算原始特征图的注意力权重，再将这些注意力权重进行融合，最后将融合后的注意力权重用于原始特征图的加权，或者将不同的注意力权重用于原始特征图加权，再将加权特征图进行融合。混合注意力机制的经典模型有卷积注意力机制模块（Convolutional Block Attention Module, CBAM）^[30]、空间与通道压缩与激励模块（Spatial and Channel Squeeze-and-Excitation, scSE）^[31] 等。

CBAM 结合了通道注意力机制与空间注意力机制，其结构如图 3.2 所示，输入特征图首先经过通道注意力模块进行加权，再通过空间注意力模块进行加权，从而得到最终结果。

具体而言，在通道注意力模块中，输入特征图分别进行空间维度上的全局最大池化和全局平均池化，再将得到的统计值分别通过一个共享权重的全连接层，最后经过逐点加和与非线性变换得到通道注意力权重，用于输入特征图的加权。空间注意力模块的输

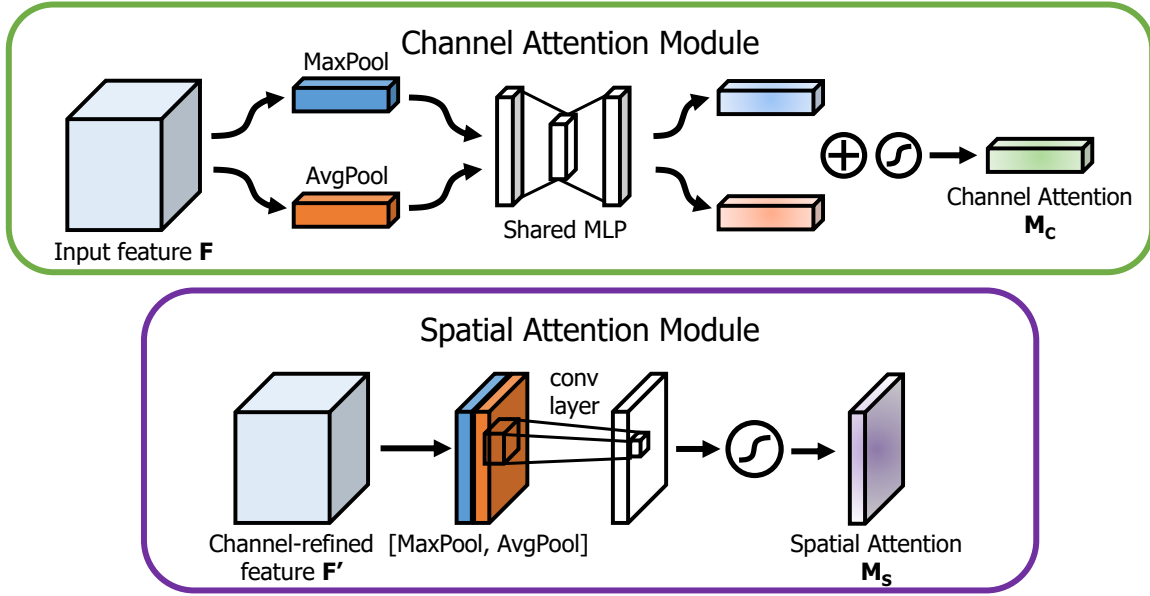


图 3.3 CBAM 模块结构

入是经过通道注意力加权的特征图，首先在通道维度上进行全局最大池化和平均池化，再将得到的统计值在通道维度进行拼接，最后经过卷积降维与非线性变换得到空间注意力权重，与特征图加权后得到最终结果。CBAM 的模块结构如图 3.3 所示。

scSE 同样结合了通道注意力机制与空间注意力机制，基于 SENet 提出了一种通道注意力模块（Channel Squeeze-and-Excitation, cSE）和一种空间注意力模块（Spatial Squeeze-and-Excitation, sSE），其结构如图 3.4 所示，不同于 CBAM，scSE 的两个子模块并行处理原始输入，分别在空间维度和通道维度对原始输入进行加权，最后再进行特征图的融合。具体而言，cSE 模块中，原始输入依次经过了空间维度的全局平均池化，通道维度的卷积降维与升维，以及非线性变换，以得到通道注意力权重。sSE 模块中，直接通过深度卷积在通道维度进行降维，再经过非线性变换以得到空间注意力权重。

3.1.2 ShallowConvNet 结合注意力机制的紧凑型 MI-EEG 分类网络

在上一节中，论文介绍了计算机视觉领域常用的注意力机制，然而，不同于图像数据，EEG 信号作为二维输入数据，并不具备深度维度信息，因此，无法直接将计算机视觉领域的注意力机制应用于 MI-EEG 分类任务中。

文献^{[26][24]}指出，在 EEG 信号解码任务中，增加神经网络的深度有利于提升解码精度。瓶颈层（Bottleneck Layer）是深度神经网络中的常见结构^{[32][33]}，通常用于对数据的降维和升维，由于采用了 1×1 卷积进行操作，瓶颈层能够有效地减少神经网络的参数。因此，论文将瓶颈层引入 ShallowConvNet 中，旨在增加较少参数量的情况下对原始输入数据进行升维操作，并在深度维度上促进时空信息的融合。

为了加快网络训练速度，并避免小数据集下过早的过拟合，论文在引入瓶颈层的基

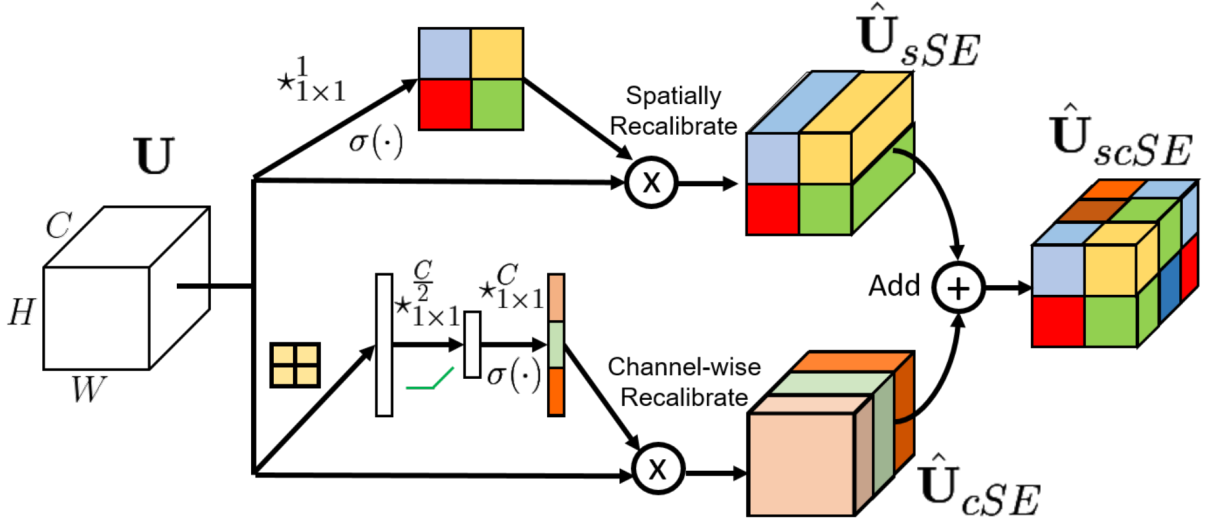


图 3.4 scSE 结构

础上，对 ShallowConvNet 的结构进行了进一步的调整：

1. 借鉴 EEGNet^[26] 的结构，将 ShallowConvNet 的时间卷积和空间卷积替换为参数量更少的深度可分离卷积^[26]；
2. 由神经科学先验知识可知，通道维度蕴含的信息量通常低于时间维度，因此，在时间卷积层之后使用瓶颈层进行适度的降维，以进一步缩减模型参数；
3. 在模型中引入了一系列正则化技术，包括批量归一化（Batch Normalization, BN）和随机 Dropout 等。

此外，论文将 ShallowConvNet 中的对数激活函数替换为 GELU 激活函数，前者基于 FBCSP 算法中的对数方差计算提出，后者基于高斯分布和自然梯度流提出，能够更自然地模拟神经元的概率行为，具有更好的连续性和光滑性^[34]，实验证明了 GELU 激活函数较之对数激活函数具有更好的效果。论文将改进后的模型称为 Base-ConvNet，并在此基础上引入注意力机制进行进一步优化。

注意力机制通过动态分配权重，使得模型能够聚焦于输入数据中的关键信息，削弱噪声的影响，混合注意力机制则结合了多种注意力机制的优点，从而能够更全面地捕获和整合不同维度的数据特征，并在许多情况下展现出优于单一注意力机制的性能。因此，论文将升维处理后的 EEG 信号视作具有深度信息的图像数据，采用结合了深度注意力和空间注意力的混合注意力机制对 Base-ConvNet 进行改进。

CBAM 模块和 scSE 模块均为轻量级注意力模块，且均兼顾深度注意力和空间注意力，但 scSE 模块在参数数量上更具优势。与此同时，文献^[31]研究发现 scSE 模块在语义分割任务上表现出色，特别是在与 EEG 信号拥有相似生理特性的医学图像的分割任

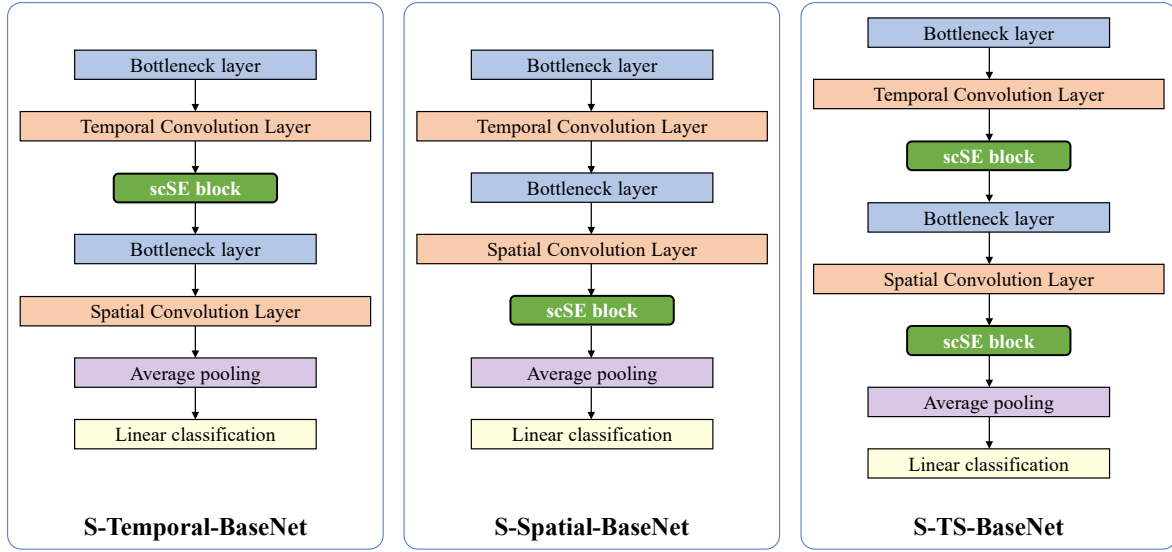


图 3.5 Base-ConvNet 引入注意力模块的方式

务，其性能优于 CBAM 模块。基于以上理由，论文选择将 scSE 模块引入 Base-ConvNet 模型中，构建紧凑型 MI-EEG 分类网络。由于 Base-ConvNet 的特征提取过程分为时间卷积和空间卷积两个阶段，scSE 模块可采取以下三种引入方式：其一是在时间卷积层后引入；其二是在空间卷积层后引入；其三是同时在时间卷积层和空间卷积层之后引入。图 3.5 展示了这三种引入 scSE 模块的方式，从左至右分别是时间卷积层后引入 scSE 模块、空间卷积层后引入 scSE 模块，以及在时间卷积和空间卷积层后均引入 scSE 模块。将这三种引入方式对应的模型分别简称为 S-Temporal-BaseNet、S-Spatial-BaseNet、S-TS-BaseNet。

表 3.1 展示了 S-Temporal-BaseNet、S-Spatial-BaseNet、S-TS-BaseNet 三种模型在 BCI Competition IV Dataset 2A^[35] 数据集上的对比实验结果。实验采用固定的参数，表格中展示的准确率（Accuracy, ACC）和 Kappa 一致性系数（Kappa）指标为数据集中九位受试者的平均表现，标准差（Standard Deviation, SD）则为准确率的标准差。从准确率和一致性分析，S-ST-BaseNet 模型的效果优于其他两种模型，与经验相符。此外，S-Temporal-BaseNet 模型的效果优于 S-Spatial-BaseNet 模型，其原因可能在于，空间卷积层沿通道维度的卷积和沿深度维度的降维使得数据损失了部分特征，进而减弱了 scSE 模块提取关键特征权重的能力，而时间卷积层保留了大部分深度信息和通道信息，因此，在时间卷积层之后加入 scSE 模块能够帮助模型更好地捕捉深度和空间的特征。从标准差分析，S-TS-BaseNet 模型的准确率波动幅度较小，对不同受试者的 MI-EEG 分类效果相对均衡，另外两种模型在不同受试者间的分类精度则存在较为明显的差异。实验数据显示，S-TS-BaseNet 模型在增加了少量参数的情况下，取得了更好的效果，因此，论文采用同时在时间卷积层和空间卷积层之后引入 scSE 模块的方式，构建基于 ShallowConvNet 和 scSE 模块的紧凑型 MI-EEG 分类网络，后文称为 S-BaseNet。

表 3.1 scSE 模块引入位置对比

Models	ACC(%)	Kappa	SD	Parameters
S-Temporal-BaseNet	78.09	0.71	10.38	4702
S-Spatial-BaseNet	77.16	0.69	10.24	4357
S-TS-BaseNet	78.55	0.71	9.46	4765

S-BaseNet 的结构如图 3.6 所示。在 ShallowConvNet 的基础上，引入了瓶颈层用于数据的升维和降维，同时，将时间卷积和空间卷积替换为深度可分离卷积，并在时间卷积层和空间卷积层之后增加了 scSE 注意力模块，其通过深度注意力机制和空间注意力机制对特征图进行注意力加权，从而增强模型对于关键特征的关注度。相较于传统卷积神经网络，S-BaseNet 具有较小的参数规模，在减小计算开销的同时能够缓解过拟合现象。

为进一步提升 S-BaseNet 模型性能，对其中的 scSE 模块进行改进。针对 sSE 模块，论文从 CBAM 模块的多维全局池化思想以及 FBCNet 模型的方差层设计^[36]得到启发，采用深度维度上的全局平均池化和全局方差计算操作代替原模块中的压缩操作，随后通过深度卷积对深度维度的特征图进行聚合，在更好地表征 EEG 信号特性的同时，进一步降低了参数规模。针对 cSE 模块，采用全局最大池化取代全局平均池化操作，实验证明了这一改动使模型具有更好的效果。此外，将 scSE 模块中的 Sigmoid 激活函数替换为 Softmax 激活函数，旨在更好地利用全局信息。论文将改良后的 scSE 模块称为 V-scSE (Variance-Informed Spatial and Channel Squeeze-and-Excitation) 模块，其结构如图 3.7 所示。使用 V-scSE 模块替换 S-BaseNet 模型中的 scSE 模块，最终得到 ShallowConvNet 结合 V-scSE 混合注意力模块的紧凑型端到端 MI-EEG 分类网络 VSNet。VSNet 网络结构能够直接处理未经过复杂预处理的原始 EEG 信号，其较小的参数规模不仅有助于缓解过拟合现象，还有利于降低计算资源消耗，提升训练速度。与此同时，ShallowConvNet 结合 V-scSE 模块的架构增强了网络对 EEG 信号重要特征的关注度，实现了 MI-EEG 分类精度的提升，取得了较为理想的性能表现。

3.2 基于密集连接改进的 Inception 模块

尽管 VSNet 作为一款紧凑型端到端网络，能够在保持极小参数规模的前提下取得相对良好的性能表现，但其网络结构中仅采用单层卷积来进行时间特征和空间特征的提取，在一定程度上限制了模型对 EEG 信号中复杂时空信息的充分捕获和深入理解。因此，对 VSNet 进行进一步优化升级，以强化其提取 EEG 信号的高维时空特征的能力，是有一定意义的。需要说明的是，在后续的优化阶段，参数量仍然是论文设计网络时考虑的因素之一，但为了增强网络对高维时空特征的提取能力，将会引入更复杂的网络结构，导致参数量的不可避免的增长。因此，在后文中，参数量将不再如前一节中一般，作为




图 3.6 S-BaseNet 结构

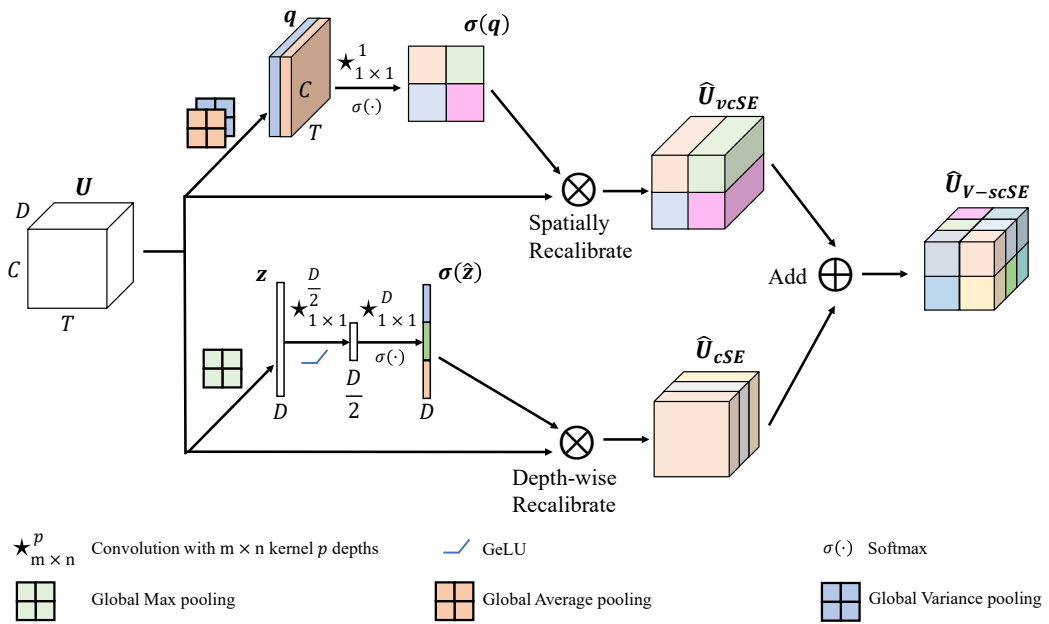


图 3.7 V-scSE 结构

衡量网络性能时的重点指标加以讨论。

3.2.1 特征提取基础结构

在 VSNet 中, 特征提取的基础结构来自于 ShallowConvNet 中的单层卷积以及 EEG-Net 中的深度可分离卷积, 其中, 提取空间特征的卷积层相较于提取时间特征的卷积层具有更少的卷积核, 这是由于 EEG 信号的空间特征复杂度通常低于时间特征复杂度, 时空信息具有不均衡性。例如, 在 BCI Competition IV Dataset 2B^[35] 数据集中, 仅仅使用了三个电极采集 MI-EEG 信号, 使得空间信息相对时间信息更为稀疏。因此, 在对 VSNet 的特征提取基础结构进行改进时, 仍然沿用更关注时间特征的策略, 即时间卷积层的复杂度要高于空间卷积层的复杂度, 这一策略的目的在于使得模型具有捕捉高维时空特征能力的同时, 防止模型因复杂度过高而在小样本数据集上过早地发生过拟合现象。

EEG 原始输入具有时间和通道两个维度的信息, 可以被视为具有空间信息的图像数据, 因此, 本节参考以下几种计算机视觉领域的经典模型, 用于 VSNet 特征提取基础结构的改进:

1. Inception 网络

Inception 模块起源于经典的 GoogLeNet 模型^[37], 并在计算机视觉图像分类任务中取得了优异的效果。传统卷积神经网络倾向于通过加深和拓宽网络结构以增进性能, 然而这种做法伴随着参数数量的激增, 不仅加大了计算负担, 还可能导致过拟合问题。在这种背景下, Inception 模块提出了多尺度特征并行抽取的策略, 旨在保持网络稀疏性的同时, 充分利用密集矩阵运算的高性能。典型的 Inception-V1 模块的结构如图 3.8 所示, 其将不同大小的卷积层和最大池化层并行排列, 并行地对输入数据执行多种卷积和池化运算, 继而将提取到的不同尺度特征在深度维度上进行拼接。这种设计能够在单层网络内并行地提取输入数据在不同层次和粒度的特征信息, 从而在高效扩展网络的深度和宽度的同时, 有效削减参数规模, 提升计算速度。此外, Inception 模块中引入了 1×1 卷积核, 用以实现深度上的特征转化和降维, 这种方式能够让模型学习到更为丰富的特征, 同时降低计算成本。后续的论文中, Inception 模块不断迭代优化, 陆续引入了批归一化、深度可分离卷积、矩阵因子分解等技术, 进一步提升了模型的性能^{[38][39]}。

2. 残差神经网络

残差神经网络 (Residual Network, ResNet)^[32] 是计算机视觉图像识别领域的一个经典模型。ResNet 研究发现了深度神经网络的退化现象 (Degradation), 即随着网络深度不断增加, 模型准确率起初随深度上升, 却在达到峰值后急剧下滑。针对这种现象, ResNet 提出了残差学习框架, 其核心思想是引入残差块 (Residual Block), 每个残差块通过快捷连接 (Shortcut Connection) 将输入信息直接输送至输出层, 使得网络只需要专注学习输入与输出之间的残差信息, 而非完整的映射关系。基础的 ResNet 由一系列残差块堆叠而成, 残差块的结构如图 3.9 所示。通过快捷连接, ResNet 在训练过程中,

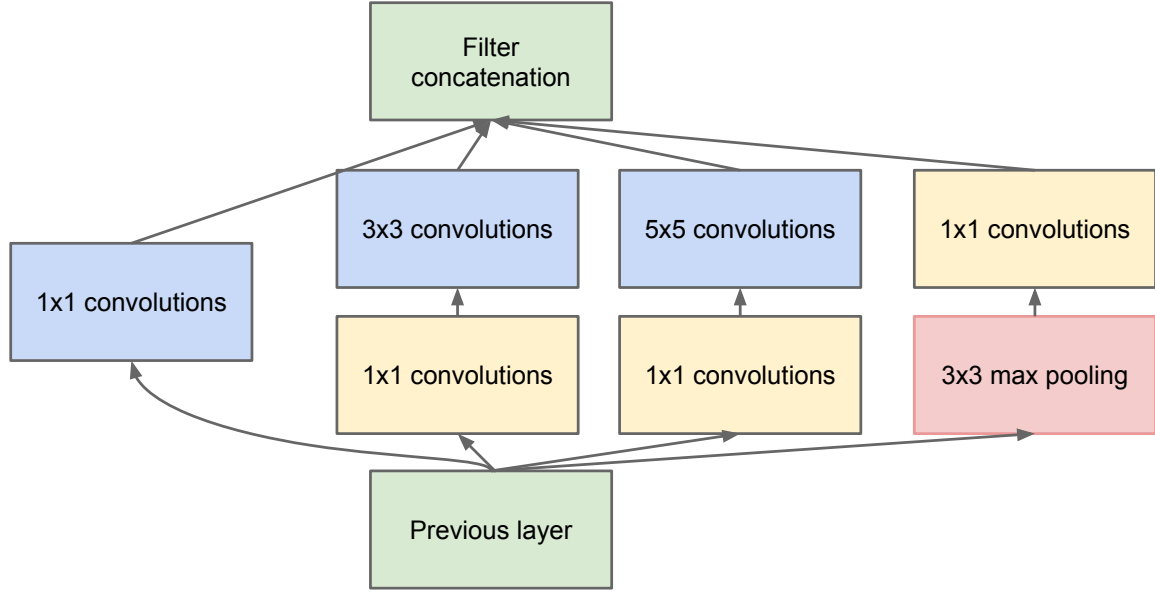


图 3.8 Inception 结构




图 3.9 残差块结构

梯度能够从深层网络直接回传至浅层，避免网络深度增加带来的训练困难和性能下降问题，从而提升深度神经网络的性能表现和训练效率。

3. U-Net

U-Net 模型^[40]最初是为生物学医学图像分割任务而设计，其具有优秀的性能，尤其在细胞、器官和病变区域的精确标注上表现出色，是医学图像分割领域的主流模型之一。U-Net 的独特之处在于其采用了对称的编码-解码结构（Encoder-Decoder）和跳跃连接（skip connection），其结构如图 3.10 所示。编码器通过连续的卷积和下采样层对输入图像进行深度特征提取和空间压缩，提炼出高级抽象特征；解码器部分则通过上采样和卷积恢复到与输入图像相同的空间分辨率，同时保留详细的定位信息。跳跃连接将编码器各阶段的特征图直接传递给相应的解码器阶段，有效地结合了包含更多细节信息的浅

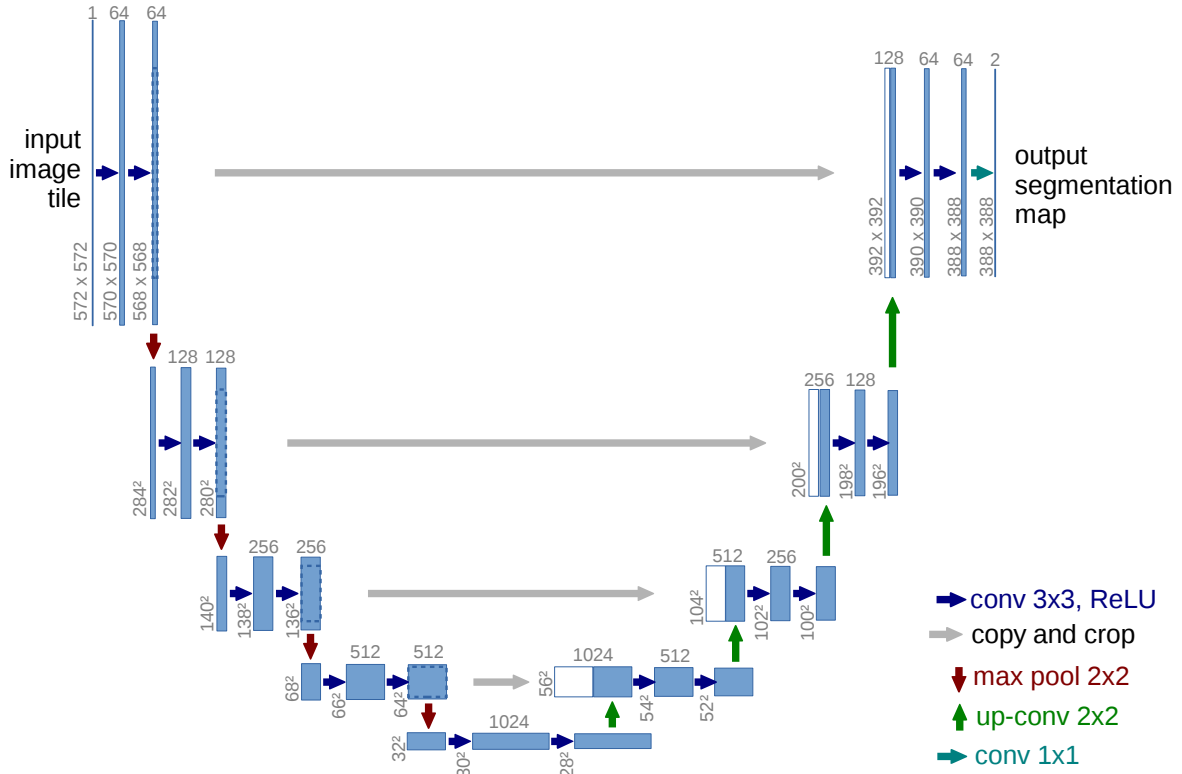


图 3.10 U-Net 结构

层特征和包含更多高级语义信息的深层特征，从而在图像分割任务中能够取得更为精细的分割效果。同时，U-Net 模型结构简单，易于训练，能够缓解小样本数据集上的过拟合问题。

在这三种模型中，Inception 和 ResNet 均在图像分类任务中展现出了优秀的性能。Inception 通过同一层网络内的多尺度特征并行抽取，在不显著增加网络深度的前提下，实现了特征提取的广度与效率的提升。ResNet 通过引入快捷连接，解决了深度神经网络训练过程中的梯度消失和退化问题，增强了深层次网络的训练效率和性能表现。U-Net 则在生物医学图像分割领域取得了优秀的表现，医学图像的语义信息较为简单，且结构较为固定，因此高级语义信息和低级特征都相对重要，U-Net 通过跳跃连接保留并融合了这两类信息，同时，U-Net 参数量较小，不容易在小样本数据集上发生过拟合现象。论文选择将 U-Net 迁移至 MI-EEG 分类任务中，是因为 EEG 信号具有与生物医学图像类似的生理特性，如特征相对简单、数据集规模偏小等。

为了验证 Inception、ResNet 与 U-Net 在 EEG 信号分类任务中的性能，论文在 BCI Competition IV Dataset 2A 数据集上进行实验对比。在实验设置中，统一将三种模型的网络深度调整为三层，并对其他关键参数如卷积核大小、学习率等进行了固定，此外，对这三种模型的原始代码进行了调整，使得其适应 MI-EEG 分类任务。实验结果如表 3.2 所示，主要展示准确率（Accuracy, ACC）和 Kappa 一致性系数（Kappa）指标，这两项指标是数据集中九位受试者的平均表现。

表 3.2 Inception、ResNet、U-Net 实验结果对比

Models	ACC(%)	Kappa
Inception	67.40	0.56
ResNet	56.94	0.43
U-Net	62.27	0.50

实验数据显示, Inception 模型在这三种模型中具有最优的性能表现, U-Net 次之, ResNet 的表现则相对较差。这可能是因为同样的网络深度下, Inception 模型得益于多尺度并行特征提取机制, 能更全面地捕获 EEG 信号的多种特征。相比之下, U-Net 虽然通过跳跃连接有效地结合了 EEG 信号的低层特征和高层语义信息, 但在解码器阶段, U-Net 将特征图重建至原始空间尺寸的过程可能为分类任务引入了不必要的复杂性。ResNet 的快捷连接在较浅层网络结构中可能未能完全发挥其优势, 更适用于深层次网络。实验结果与过往研究中关于浅层网络更适合 MI-EEG 分类任务的研究结论相互印证。综上所述, 论文选用 Inception 模块用于 VSNet 特征提取结构的改进, 旨在保持模型简洁高效的同时, 在 MI-EEG 分类任务中取得更好的性能。

3.2.2 密集连接

在前一节中, 论文选取了 Inception 模块作为改进 VSNet 的方案, 然而, 值得注意的是, U-Net 在处理 MI-EEG 分类任务时同样展现了一定的优势。由于 EEG 信号的特征相对简单, 因此低级特征与高级语义信息都相对重要, U-Net 因其特殊的跳跃连接结构有效地融合了这两种信息, 然而, U-Net 中通过解码器阶段将特征图恢复至原始空间尺寸的操作并非必要, 因为在分类任务中, 这种重建过程可能导致额外的计算负担且对分类性能的提升效果不明显。因此, 在对 VSNet 进行改进时, 论文从 U-Net 兼顾低级特征与高级语义信息的策略中得到启发, 同时对不必要的特征图空间尺寸还原过程进行规避, 以构建一个既能充分利用 EEG 信号中各级别特征信息, 又具备高效计算能力的改进模型。

Gao Huang 等人于 2016 年提出了密集连接网络^[33] (Dense Convolutional Network, DenseNet)。在 ResNet 的基础上, DenseNet 提出了一种更为激进的连接模式: 引入从任意层到后续层的直接连接, 即密集连接 (Dense Connection)。DenseNet 的第 l 层接收所有前序特征图为输入, 其输出为 x_l :

$$x_l = H_l([x_0, x_1, \dots, x_{l-1}]) \quad (3.1)$$

其中, $[x_0, x_1, \dots, x_{l-1}]$ 代表第 $0, \dots, l-1$ 层的输出特征图, $H_l(\cdot)$ 代表非线性转换复合函数, 可能包括一系列的批量归一化、ReLU、池化及卷积操作。密集连接的结构如图 3.11 所示。




图 3.11 密集连接结构

在密集连接模块中，所有的前序特征图通过 **Concentrate** 在深度维度上连接在一起，因此，在一个密集连接模块中所有特征图的大小是相同的。**DenseNet** 提出了 **Transaction** 模块用于连接两个相邻的密集连接模块，并通过池化操作对特征图进行下采样，从而减小特征图的大小。

通过密集连接的方式，网络中的每一层都能够访问并整合所有前序层提取出的特征信息，进而充分利用 EEG 信号中的低层特征细节和高层语义信息。相较于 **U-Net** 中的编码-解码结构，密集连接无需经历数据空间的重建过程，即可实现特征的有效复用。此外，**DenseNet** 中的 **Transition** 模块也为实现特征图的下采样提供了思路。

3.2.3 基于密集连接改进的 Inception 模块

原始的 **Inception** 模块和密集连接模块在计算机视觉图像分类任务中都取得了优秀的表现，在设计上，它们都考虑到了图像数据在空间维度具有等价的重要性。然而，EEG 信号的时空信息具有不均衡的重要性，通常情况下，时间维度往往比空间维度蕴含更为丰富的信息。与此同时，研究指出^[26]，当设计用于提取 EEG 特征的卷积核时，将时间卷积核长度设置为 EEG 信号采样率的一半，可以有效地捕获 2Hz 及以上频段的信号信息。因此，在处理 EEG 信号时，时间卷积核的长度应当依据 EEG 信号的实际采样率来灵活设定，以便提取不同频率成分的信号特征。

鉴于上述 EEG 信号与图像数据的特性差异，原始的 **Inception** 模块和密集连接模块在未经适当改造的情况下，并不适合直接应用于 MI-EEG 分类任务。为此，有必要对这些模块进行针对性的调整和优化，以适应 EEG 信号的特性和 MI-EEG 分类任务的需求。

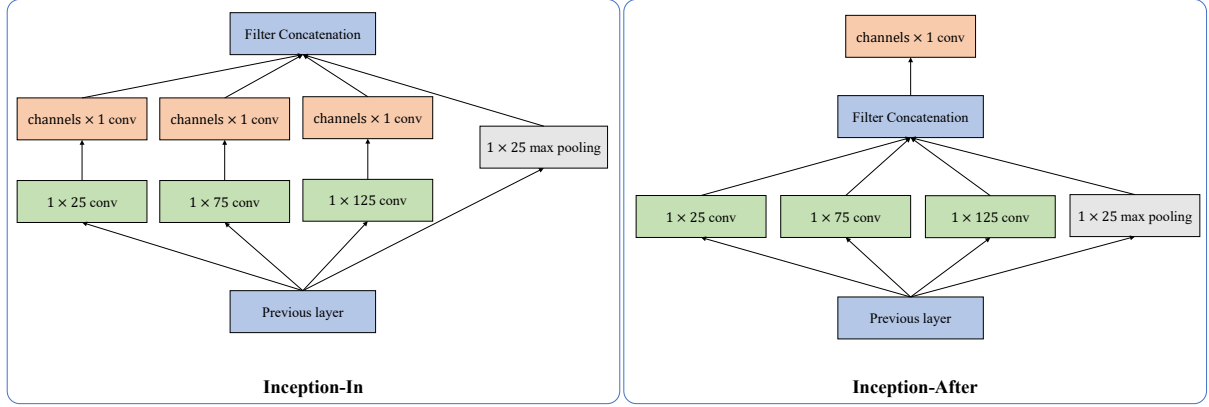


图 3.12 Inception 模块引入空间卷积层的方式

鉴于 EEG 信号的时间维度蕴含着更为丰富的信息，论文对 VSNet 中的时间卷积层进行进一步的优化。论文将 Inception 模块中的卷积核概念转化为针对时间序列的一维卷积（尽管在实现时仍采用二维卷积），舍弃了原始 Inception 模块中针对图像数据的空间可分离卷积设计。为了更好地匹配 EEG 信号的采样特性及其内在频率成分，依据 EEG 信号的采样频率 $sfreq$ 来动态调整 Inception 模块各个分支的时间卷积核大小，具体公式如下：

$$kernel_i = sfreq \times time_unit_i, \quad time_unit_i \in \{0.1, 0.3, \dots, 0.9\} \quad (3.2)$$

其中， $kernel_i$ 表示 Inception 模块第 i 个分支所使用的卷积核大小，而 $sfreq$ 是 EEG 信号的采样频率， $time_unit_i$ 则为卷积核对应的时间单位，其取值范围分布在 0.1 秒至 0.9 秒的奇数间隔内。这样设置卷积核大小是为了更全面地捕捉 EEG 信号中不同频率成分的特征信息，同时避免因卷积核大小过于接近而导致提取的特征之间重叠度过高。例如，当采样周期设定为 0.5 秒时，卷积核大小将是采样率的一半，进而能够有效地捕获到 2Hz 及更高频段的 EEG 信号特征。

原始 Inception 模块中采用了瓶颈层进行特征降维，然而考虑到在 VSNet 架构中，时间卷积层前置了瓶颈层对 EEG 信号进行适当的特征升维以挖掘更多信息，论文决定舍弃原始 Inception 模块中可能导致 EEG 信号特征损失的降维瓶颈层设计方案。

在构建 VSNet 时，空间卷积层有两种不同的方式融入基于 Inception 改进的时间卷积层之后，一种是在每个 Inception 模块内部的分支结构上增加空间卷积层，另一种则是在整个 Inception 模块之后附加空间卷积层。图 3.12 展示了这两种引入方式的差别，将这两种方式分别称为分支内融合（Inception-In）和模块后融合（Inception-After），需要说明的是，图中省略了网络的其他结构，如瓶颈层等，以尽可能简洁地展现不同引入方式的差异。

为了比较 Inception-In 与 Inception-After 的性能差异，论文在 BCI Competition IV Dataset 2A 数据集上设计实验进行对比。在实验设置阶段，固定了 Inception 模块的层次

数量、分支数量等参数，实验结果如表 3.3 所示。在此，重点关注两项评价指标——准确率（Accuracy, ACC）和 Kappa 一致性系数（Kappa），这两项指标均基于数据集中九位受试者的平均表现。实验结果显示，Inception-After 方式在准确率和一致性系数上均表现更优。这一优势可能源自两方面的原因：一方面，虽然 Inception-In 模式借鉴了 FBCSP 算法的分频段处理思路，但在 Inception 分支内部直接进行空间特征提取的过程中，损失了部分空间全局信息；另一方面，Inception-In 结构具有相对更大的参数规模，这可能导致模型在有限样本条件下更容易出现过拟合现象。基于以上分析和实验验证，论文选择以 Inception-After 的方式布局时间卷积层与空间卷积层。

表 3.3 Inception-In、Inception-After 实验结果对比

Models	ACC(%)	Kappa
Inception-In	63.31	0.51
Inception-After	75.35	0.70

在以上改进的基础上，为了同时充分挖掘和利用 EEG 信号中的低级特征与高级语义信息，论文选择在 Inception 模块中引入密集连接的概念，替代原有的时间卷积核设计。在 DenseNet 中，有两种不同构造的密集连接模块，分别是基础密集连接模块（Basic Dense Block）和带有瓶颈层的密集连接模块（Bottleneck Dense Block），它们的区别主要体现在非线性转换复合函数 $H(\cdot)$ 的设计上：

1. 基础密集连接模块（Basic Dense Block）：

其非线性转换复合函数定义为： $H(\cdot) = BN + ReLU + 3 \times 3 \text{ conv}$ 。

2. 瓶颈密集连接模块（Bottleneck Dense Block）：

其非线性转换复合函数更为复杂，包括两个卷积层、两次 BN 和 ReLU 激活： $H(\cdot) = BN + ReLU + 1 \times 1 \text{ conv} + BN + ReLU + 3 \times 3 \text{ conv}$ 。加入瓶颈层的主要原因在于降低特征维度的数量，从而提升模型计算效率。

论文对 Inception 模块第 i 个分支采用了基于 Bottleneck Dense Block 的密集连接模块，并对其进行了适当调整，定义的非线性转换复合函数 $H(\cdot)$ 如下：

$$H(\cdot) = BN + GeLU + 1 \times 1 \text{ conv} + BN + 1 \times kernel_i \text{ conv} + Dropout \quad (3.3)$$

$$kernel_i = sfreq \times time_unit_i, \quad time_unit_i \in \{0.1, 0.3, \dots, 0.9\}$$

相较于原始的 Bottleneck Dense Block，论文在前文研究的基础上做出了以下改进，分别为：根据 EEG 信号的特性调整了卷积核大小；选用性能更优的激活函数 GeLU 替代 ReLU；引入了 Dropout 层，以进一步缓解过拟合现象。

经过上述基于密集连接策略的改进，新构建模型的结构如图 3.13 所示，将其命名为 DI-VSNet。Dense-Inception module 构成了时间卷积层，其内部的各个分支均由一系列改进版的 Bottleneck Dense Block 紧密堆叠而成，形成密集连接结构，用以同时获取浅层

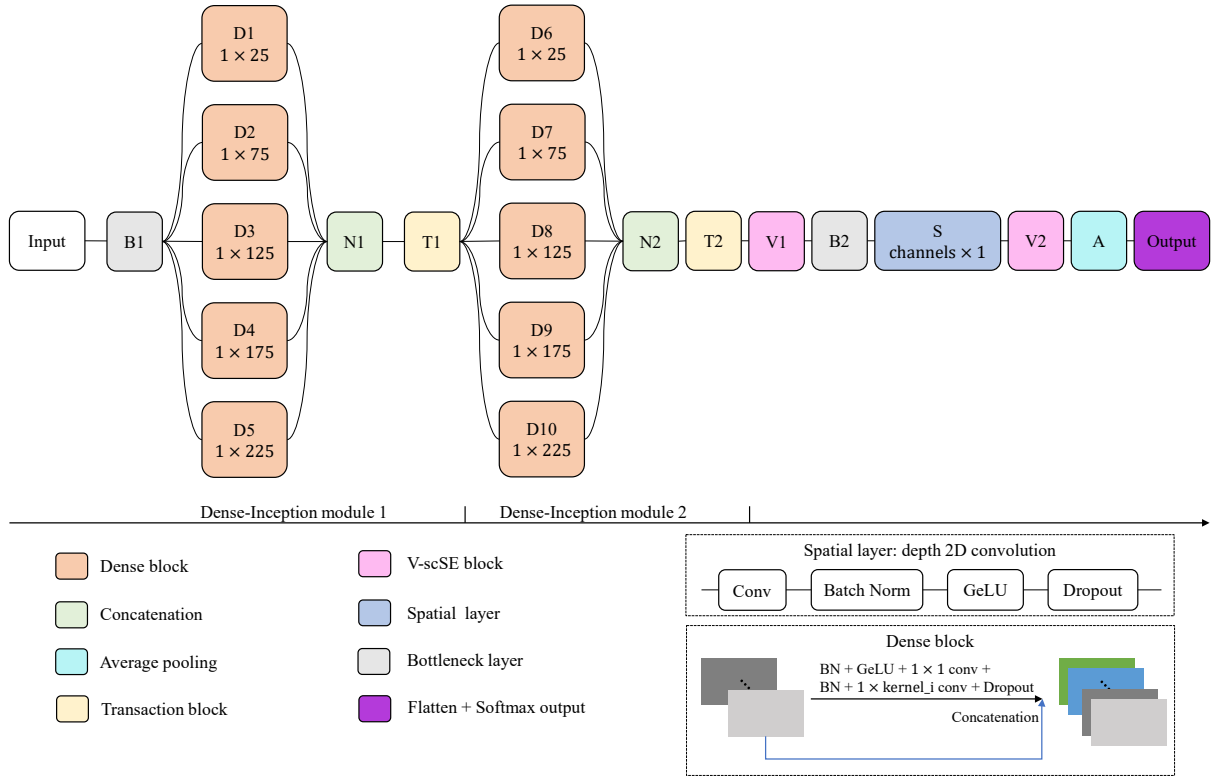


图 3.13 DI-VSNet 结构

和深层的时间特征。每个分支提取的特征图在深度维度上进行聚合，并通过 Transaction 模块进行深度压缩和特征整合，以进一步提升模型的表达能力和计算效率。

3.3 基于软阈值化改进的 Transformer 模块

3.4 基于 Inception 和混合注意力的运动想象脑电图分类网络 HIT-Net

3.5 本章小结

4 实验结果分析与模型评估

5 总结与展望

参考文献

- [1] 蒲慕明. 脑科学的未来[J]. 心理学通讯, 2019, 2: 80-83.
- [2] 蒲慕明. 脑科学研究的三大发展方向[J]. 中国科学院院刊, 2019, 34: 807-813.
- [3] JORGENSEN L A, NEWSOME W T, ANDERSON D J, et al. The brain initiative: developing technology to catalyse neuroscience discovery[J]. Philosophical Transactions of the Royal Society B: Biological Sciences, 2015, 370(1668): 20140164.
- [4] OKANO H, MIYAWAKI A, KASAI K. Brain/minds: brain-mapping project in japan[J]. Philosophical Transactions of the Royal Society B: Biological Sciences, 2015, 370(1668): 20140310.
- [5] NADDAF M. Europe spent€ 600 million to recreate the human brain in a computer. how did it go?[J]. Nature, 2023, 620(7975): 718-720.
- [6] 中华人民共和国科学技术部. 科技部关于发布科技创新 2030 — “脑科学与类脑研究” 重大项目 2021 年度项目申报指南的通知[EB/OL]. 2021[2022-06-01]. https://service.most.gov.cn/kjjh_tztg_all/20210916/4583.html.
- [7] MING POO M, LIN DU J, IP N, et al. China brain project: Basic neuroscience, brain diseases, and brain-inspired computing[J/OL]. Neuron, 2016, 92(3): 591-596. <https://www.sciencedirect.com/science/article/pii/S0896627316308005>.
- [8] HE B, YUAN H, MENG J, et al. Brain–computer interfaces[J]. Neural engineering, 2020: 131-183.
- [9] PICHIORRI F, MORONE G, PETTI M, et al. Brain–computer interface boosts motor imagery practice during stroke recovery[J]. Annals of neurology, 2015, 77(5): 851-865.
- [10] ALTAHERI H, MUHAMMAD G, ALSULAIMAN M, et al. Deep learning techniques for classification of electroencephalogram (eeg) motor imagery (mi) signals: A review[J]. Neural Computing and Applications, 2023, 35(20): 14681-14722.
- [11] SAI C Y, MOKHTAR N, AROF H, et al. Automated classification and removal of eeg artifacts with svm and wavelet-ica[J]. IEEE journal of biomedical and health informatics, 2017, 22(3): 664-670.
- [12] HJORTH B. Eeg analysis based on time domain properties[J/OL]. Electroencephalography and Clinical Neurophysiology, 1970, 29(3): 306-310. <https://www.sciencedirect.com/science/article/pii/0013469470901434>.
- [13] LUKE R, WOUTERS J. Kalman filter based estimation of auditory steady state response parameters[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering,

2017, 25(3): 196-204.

- [14] HSU W Y. Eeg-based motor imagery classification using neuro-fuzzy prediction and wavelet fractal features[J/OL]. *Journal of Neuroscience Methods*, 2010, 189(2): 295-302. <https://www.sciencedirect.com/science/article/pii/S0165027010001858>.
- [15] WANG Y, GAO S, GAO X. Common spatial pattern method for channel selection in motor imagery based brain-computer interface[C]//2005 IEEE engineering in medicine and biology 27th annual conference. IEEE, 2006: 5392-5395.
- [16] ANG K K, CHIN Z Y, ZHANG H, et al. Filter bank common spatial pattern (fbcsp) in brain-computer interface[C]//2008 IEEE international joint conference on neural networks (IEEE world congress on computational intelligence). IEEE, 2008: 2390-2397.
- [17] DORNHEGE G, BLANKERTZ B, KRAULEDAT M, et al. Combined optimization of spatial and temporal filters for improving brain-computer interfacing[J]. *IEEE transactions on biomedical engineering*, 2006, 53(11): 2274-2281.
- [18] LEMM S, BLANKERTZ B, CURIO G, et al. Spatio-spectral filters for improving the classification of single trial eeg[J]. *IEEE transactions on biomedical engineering*, 2005, 52(9): 1541-1548.
- [19] MOUSAVI E A, MALLER J J, FITZGERALD P B, et al. Wavelet common spatial pattern in asynchronous offline brain computer interfaces[J]. *Biomedical Signal Processing and Control*, 2011, 6(2): 121-128.
- [20] WANG S J, CAI Y X, SUN Z R, et al. Tinnitus eeg classification based on multi-frequency bands[C]//Neural Information Processing: 24th International Conference, ICONIP 2017, Guangzhou, China, November 14–18, 2017, Proceedings, Part IV 24. Springer, 2017: 788-797.
- [21] KROUPI E, YAZDANI A, EBRAHIMI T. Eeg correlates of different emotional states elicited during watching music videos[C]//Affective Computing and Intelligent Interaction: Fourth International Conference, ACII 2011, Memphis, TN, USA, October 9–12, 2011, Proceedings, Part II. Springer, 2011: 457-466.
- [22] HERMAN P, PRASAD G, MCGINNITY T M, et al. Comparative analysis of spectral approaches to feature extraction for eeg-based motor imagery classification[J]. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 2008, 16(4): 317-326.
- [23] PAWAR D, DHAGE S. Feature extraction methods for electroencephalography based brain-computer interface: A review[J]. *IAENG International Journal of Computer Science*, 2020, 47(3).
- [24] SCHIRRMESTER R T, SPRINGENBERG J T, FIEDERER L D J, et al. Deep learning with convolutional neural networks for eeg decoding and visualization[J]. *Human brain*

- mapping, 2017, 38(11): 5391-5420.
- [25] SAKHAVI S, GUAN C, YAN S. Parallel convolutional-linear neural network for motor imagery classification[C]//2015 23rd European signal processing conference (EUSIPCO). IEEE, 2015: 2736-2740.
- [26] LAWHERN V J, SOLON A J, WAYTOWICH N R, et al. Eegnet: a compact convolutional neural network for eeg-based brain-computer interfaces[J]. Journal of neural engineering, 2018, 15(5): 056013.
- [27] ITTI L, KOCH C, NIEBUR E. A model of saliency-based visual attention for rapid scene analysis[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(11): 1254-1259.
- [28] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 7132-7141.
- [29] JADERBERG M, SIMONYAN K, ZISSERMAN A, et al. Spatial transformer networks [J]. Advances in neural information processing systems, 2015, 28.
- [30] WOO S, PARK J, LEE J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [31] ROY A G, NAVAB N, WACHINGER C. Concurrent spatial and channel squeeze & excitation in fully convolutional networks[C]//Medical Image Computing and Computer Assisted Intervention-MICCAI 2018: 21st International Conference, Granada, Spain, September 16-20, 2018, Proceedings, Part I. Springer, 2018: 421-429.
- [32] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [33] HUANG G, LIU Z, VAN DER MAATEN L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.
- [34] HENDRYCKS D, GIMPEL K. Gaussian error linear units (gelus)[J]. arXiv preprint arXiv:1606.08415, 2016.
- [35] TANGERMANN M, MÜLLER K R, AERTSEN A, et al. Review of the bci competition iv[J]. Frontiers in neuroscience, 2012, 6: 21084.
- [36] MANE R, CHEW E, CHUA K, et al. Fbcnet: A multi-view convolutional neural network for brain-computer interface[J]. arXiv preprint arXiv:2104.01233, 2021.
- [37] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
- [38] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the inception architecture for

- computer vision[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 2818-2826.
- [39] SZEGEDY C, IOFFE S, VANHOUCKE V, et al. Inception-v4, inception-resnet and the impact of residual connections on learning[C]//Proceedings of the AAAI conference on artificial intelligence: volume 31. 2017.
- [40] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18. Springer, 2015: 234-241.

致谢

以简短的文字表达作者对完成论文和学业提供帮助的老师、同学、领导、同事及亲属的感激之情。